Genomic Data Science হলো এমন একটি গবেষণা ক্ষেত্র

যেখানে জিনোমিক ডেটা **(DNA/RNA** সম্পর্কিত তথ্য**)** বিশ্লেষণ করতে ডেটা সায়েন্স**,** পরিসংখ্যান এবং মেশিন লার্নিং ব্যবহার করা হয়।

সহজ ভাষায় বললে:

👉 মানুষের শরীরের ভেতরে যে **DNA** আছে, সেই DNA–এর বিশাল তথ্য (genomic data) কম্পিউটার ও অ্যালগরিদম দিয়ে বিশ্লেষণ করাই হলো Genomic Data Science।

🔬 **Genomics** কী?

Genomics হলো জীবের সম্পূর্ণ জিনোম **(Genome)** — অর্থাৎ পুরো DNA সেট — নিয়ে গবেষণা।

💻 **Data Science** কীভাবে যুক্ত?

Genomic data খুব বড় (Big Data)। তাই এগুলো বিশ্লেষণ করতে লাগে:

- Python / R প্রোগ্রামিং
- Machine Learning
- Deep Learning
- Bioinformatics tools

🧬 **Genomic Data Science** কী কাজ করে?

1. রোগের জেনেটিক কারণ খুঁজে বের করা
2. ক্যান্সার বিশ্লেষণ
3. ব্যক্তিগত চিকিৎসা (Personalized Medicine)
4. Drug discovery
5. ভাইরাস বিশ্লেষণ (যেমন COVID-19 genome study)

📊 উদাহরণ

ধরো, কারো ক্যান্সার হয়েছে। বিজ্ঞানীরা তার DNA বিশ্লেষণ করে দেখতে পারেন কোন জিনে সমস্যা আছে। Machine Learning মডেল ব্যবহার করে ভবিষ্যতে রোগের ঝুঁকি অনুমানও করা যায়।

🎯 এই বিষয়ে পড়াশোনায় লাগে:

- Biology এর বেসিক ধারণা
- Programming (Python বেশি ব্যবহার হয়)
- Statistics
- Machine Learning

Genomic Data Science thesis topic

🧬 ১. Cancer Gene Mutation Prediction using Machine Learning

বিষয়: ক্যান্সার সম্পর্কিত জিন মিউটেশন পূর্বাভাস
কাজ কী হবে?

- DNA sequence ডেটা সংগ্রহ
- Feature extraction
- ML model (Random Forest / SVM / Neural Network) দিয়ে mutation prediction

🎯 Outcome: কোন gene mutation ক্যান্সারের সাথে সম্পর্কিত তা পূর্বাভাস করা।

🧬 ২. DNA Sequence Classification using Deep Learning

বিষয়: Deep Learning দিয়ে DNA সিকোয়েন্স শ্রেণিবিন্যাস
ব্যবহার করা যেতে পারে:

- CNN
- LSTM
- Transformer (BERT-based model)

🎯 Outcome: DNA sequence কোন প্রজাতির বা কোন রোগের তা নির্ণয়।

🧬 ৩. Personalized Medicine Prediction System

বিষয়: জেনেটিক তথ্য দিয়ে ব্যক্তিগত চিকিৎসা পূর্বাভাস
কাজ:

- রোগীর genetic data বিশ্লেষণ
- কোন ওষুধ কার্যকর হবে তা predict করা

🎯 Outcome: Precision medicine system তৈরি।

🧬 ৪. Genetic Disease Risk Prediction using Machine Learning

বিষয়: বংশগত রোগের ঝুঁকি নির্ণয়
উদাহরণ রোগ:

- Diabetes
- Breast Cancer
- Alzheimer’s

🎯 Outcome: Genetic markers দিয়ে risk prediction model।

🧬 ৫. COVID-19 Genome Analysis using Bioinformatics & ML

বিষয়: ভাইরাস genome বিশ্লেষণ
কাজ:

- Virus mutation tracking
- Variant classification

🎯 Outcome: নতুন ভ্যারিয়েন্ট শনাক্তকরণ মডেল।

📂 Dataset কোথায় পাবে?

তুমি dataset পেতে পারো:

- Kaggle
- NCBI
- The Cancer Genome Atlas
- UCI Machine Learning Repository

🎓 Beginner হলে কোনটা নেবে?

তুমি যদি এখন শুরু করো, তাহলে এইটা সবচেয়ে safe:

👉 **Genetic Disease Risk Prediction using Machine Learning**

কারণ:

- Dataset পাওয়া সহজ
- Coding manageable
- Presentation ভালো করা যায়
- ML knowledge apply করা যাবে

(Research problem + Objective + Dataset + Model + Methodology সহ) 🚀

Genomic Data Science

Dataset:

#1 Liver Cirrhosis

#2 mutation analysis cancer

1.https://www.kaggle.com/code/arjunbhaybhang/liver-cirrhosis-prediction-with-xgboost-eda

2.https://www.kaggle.com/code/vizeno/liver-cirrhosis-prediction-eda-models

3.https://www.kaggle.com/code/totoro29/cirrhosis-liver-disease-eda-prediction

4.https://www.kaggle.com/code/miadul/liver-cancer-risk-modeling-with-full-eda-visual

5.https://www.kaggle.com/code/zgrumutpirin/liver-cirrhosis-data-analysis

6.https://www.kaggle.com/datasets/datasetengineer/lungcanc2024

7.https://www.kaggle.com/datasets/janasaffour/breast-cancer-ml-dataset

বিপুল পরিমাণ এবং উচ্চমানের ***Genomic Data Science*** ও ***Bioinformatics*** ডেটাসেটের জন্য শুধুমাত্র ***Kaggle-***এর ওপর নির্ভর না করে আপনি নিচের বিশ্বস্ত সোর্সগুলো ব্যবহার করতে পারেন। যেহেতু আপনি লিভার সিরোসিস এবং ক্যান্সার মিউটেশন নিয়ে কাজ করছেন, এই প্ল্যাটফর্মগুলো আপনার জন্য অনেক বেশি কার্যকর হবে:

১. NCBI - Gene Expression Omnibus (GEO)

এটি বায়োইনফরমেটিক্স রিসার্চের জন্য সবচেয়ে বড় পাবলিক রিপোজিটরি। এখানে বিভিন্ন রোগের (যেমন: ক্যান্সার বা লিভার ডিজিজ) মাইক্রোঅ্যারে (Microarray) এবং নেক্সট-জেনারেশন সিকোয়েন্সিং (NGS) ডেটা পাওয়া যায়।

* **কিভাবে খুঁজবেন:** NCBI GEO :

https://www.ncbi.nlm.nih.gov/geo/

তে গিয়ে "Liver Cirrhosis" বা "Cancer Mutation" লিখে সার্চ দিন। এখানে আপনি GSE আইডি যুক্ত আসল রিসার্চ ডেটা পাবেন।

২. The Cancer Genome Atlas (TCGA) / GDC Data Portal

ক্যান্সার মিউটেশন অ্যানালাইসিসের জন্য এটি গোল্ড স্ট্যান্ডার্ড। এখানে ৩৩ ধরনের ক্যান্সারের হাজার হাজার রোগীর জিনোমিক ডেটা আছে।

* **কিভাবে খুঁজবেন:** GDC Data Portal :

https://portal.gdc.cancer.gov/

এ গিয়ে 'Primary Site' হিসেবে 'Liver' বা 'Lung' সিলেক্ট করে মিউটেশন ডেটা ডাউনলোড করতে পারেন।

৩. UCI Machine Learning Repository

Kaggle-এর মতো এখানেও ক্লিনিকাল ডেটাসেট পাওয়া যায় যা মেশিন লার্নিং মডেলিংয়ের জন্য খুব ভালো।

* **লিঙ্ক:** UCI Repo : https://archive.ics.uci.edu/

৪. cBioPortal for Cancer Genomics

এটি ***TCGA*** এবং অন্যান্য প্রজেক্টের জটিল ডেটাকে খুব সহজে ব্রাউজ করার সুযোগ দেয়। আপনি এখান থেকে সরাসরি ক্লিনিকাল এবং মিউটেশন ডেটা ফাইল হিসেবে ডাউনলোড করতে পারেন।

* **লিঙ্ক:** ***cBioPortal : https://www.cbioportal.org/***

৫. লিভার সিরোসিস ও ক্যান্সারের জন্য স্পেসিফিক সোর্স

আপনার দেওয়া লিঙ্কগুলোর ওপর ভিত্তি করে আপনি এই স্পেসিফিক পোর্টালগুলো দেখতে পারেন:

* ***ICGC (International Cancer Genome Consortium):*** বিভিন্ন দেশের ক্যান্সার প্রজেক্টের ডেটা এখানে থাকে।

* ***Cosmic (Catalogue of Somatic Mutations in Cancer):*** ক্যান্সার মিউটেশন নিয়ে বিস্তারিত তথ্যের জন্য এটি সেরা।

ডেটাসেট নির্বাচনের জন্য কিছু টিপস:

১. ***Data Format:*** লক্ষ্য রাখবেন ফাইলটি কি ***.csv*** ফর্মে আছে নাকি ***.fasta, .vcf*** বা ***.fastq*** ফর্মে। ক্লিনিকাল প্রেডিকশনের জন্য ***.csv*** ভালো, কিন্তু পিওর জিনোমিক অ্যানালাইসিসের জন্য বায়োইনফরম্যাটিক ফরম্যাটগুলো শিখতে হবে।

২. ***Authenticity:*** যেহেতু আপনি থিসিসের জন্য কাজ করছেন, চেষ্টা করবেন ***NCBI*** বা ***TCGA*** থেকে ডেটা নিতে, কারণ এগুলোর সাইটেশন ভ্যালু অনেক বেশি।

আপনি যদি নির্দিষ্ট কোনো ফরম্যাটে (যেমন: শুধুমাত্র ***RNA-seq*** বা ***DNA Methylation)*** ডেটা খুঁজছেন, তবে জানাবেন, আমি সরাসরি সেই লিঙ্ক খুঁজে দিতে পারব।

1. ***First GPT LINK :*** ***https://chatgpt.com/share/69a5302e-38f8-8002-be60-2874c04ab71e***
2. ***Secound :*** ***https://chatgpt.com/share/6a28bb7d-e4f0-8322-addf-a08a17fc7a92***

#SCound LINK details:

i)first search Genomic Data Science এটা নিয়ে ***thesis*** করলে ***title*** কী দিব ***without ai***

Output:

এখানে কিছু ***professional, research-friendly*** এবং ***“without AI”*** ভিত্তিক ***thesis title*** দিলাম যেগুলো ***Genomic Data Science*** এর জন্য ***suitable*** হবে***:***

1. ***Comparative Analysis of Human Genomic Variations Using Bioinformatics Techniques***
2. ***Genome Sequence Analysis for Identification of Genetic Mutations***
3. ***A Study on DNA Sequence Patterns and Genetic Diversity***

4. ***Genomic Data Analysis for Disease Prediction and Classification***
5. ***Identification of Genetic Markers Through Genome Data Processing***
6. ***Analysis of Genomic Variants Associated with Inherited Diseases***
7. ***Bioinformatics Approaches for Large-Scale Genome Data Interpretation***
8. ***Study of Gene Expression Patterns Using Genomic Data Analysis***
9. ***Genome-Based Detection of Hereditary Disorders Using Computational Methods***
10. ***Statistical Analysis of Genomic Data for Understanding Genetic Disorders***
11. ***Exploring DNA Sequence Alignment Techniques in Genomic Data Science***
12. ***A Computational Study of Human Genome Variability and Mutation Detection***

আরও একটু ***"glorious"*** বা ***university-level attractive title*** চাইলে:

- ***Decoding the Human Genome: A Computational Approach to Genetic Variation Analysis***
- ***Genomic Insights into Human Genetic Disorders Through Bioinformatics Analysis***
- ***Exploration of Genome Variability Using Modern Genomic Data Science Techniques***

- ***Computational Analysis of Genomic Data for Understanding Human Genetic Diversity***

Easy + workable + without AI হিসেবে সবচেয়ে ভালো হতে পারে***:***

"Genome Sequence Analysis for Identification of Genetic Mutations"

কারণ এতে***:***

- ***Dataset*** পাওয়া সহজ
- ***Bioinformatics tools*** ব্যবহার করা যায়
- ***Coding + analysis*** দুটোই করা যায়
- ***Thesis comparatively*** সহজ হয়

ii)আরো বড় ***Professional title*** দাও

secound search output

ঠিক আছে—এখানে আমি তোমার জন্য আরও বড়, বেশি ***"professional + thesis-level"*** টাইটেল দিলাম, যেগুলো ***Genomic Data Science*** এর জন্য একদম উপযুক্ত এবং ***university thesis*** হিসেবে ***strong*** দেখাবে***:***

🔬 ***Advanced Professional Thesis Titles***

1. ***Comprehensive Computational Analysis of Human Genomic Data for the Identification and Characterization of Disease-Associated Genetic Variations***
2. ***A Large-Scale Bioinformatics Approach for the Analysis of Genomic Sequences to Detect Genetic***

Mutations and Their Association with Complex Diseases

3. ***Integrative Genomic Data Science Framework for the Analysis of Gene Expression Patterns and Identification of Disease Biomarkers***
4. ***Genome-Wide Computational Analysis for the Detection of Genetic Variants and Their Functional Impact on Human Diseases***
5. ***Advanced Bioinformatics and Statistical Modeling of Genomic Data for Understanding Genetic Diversity and Disease Susceptibility***
6. ***A Multi-Dataset Comparative Genomic Study for Identification of Differential Gene Expression in Cancer and Liver Disease***
7. ***Computational Investigation of Human Genome Variability Using High-Throughput Sequencing Data and Bioinformatics Pipelines***
8. ***Large-Scale Genomic Data Mining and Analysis for the Discovery of Novel Genetic Markers Associated with Chronic Diseases***
9. ***Systematic Analysis of Genomic Variations and Gene Expression Profiles Using Bioinformatics and Statistical Techniques***
10. ***Integrated Computational Framework for Genome Sequence Analysis, Mutation Detection, and Disease Association Studies***

⭐ ***Bonus (Very Strong University-Level Title)***

“A Comprehensive Computational and Statistical Analysis of Human Genomic Data for the Identification of Disease-Associated Genetic Mutations and Functional Genomic Variations”

#Perfect thesis title final করে দাও

তোমার দেওয়া দুইটা ***dataset (Cancer + Liver disease)*** এবং ***Genomic Data Science***–এই কনটেক্সট অনুযায়ী সবচেয়ে ***strong, professional*** এবং ***thesis-ready final title***টা হলো***:***

Final Thesis Title (Perfect Version)

“A Comprehensive Comparative Genomic Data Science Analysis of Cancer and Liver Disease Datasets for the Identification of Differential Gene Expression Patterns and Disease-Associated Genetic Variations”

#DATA SET LINK:

https://www.ncbi.nlm.nih.gov/geo/query/acc.cgi?acc=GSE329336 ----- Cancer

https://www.ncbi.nlm.nih.gov/geo/query/acc.cgi?acc=GSE280687 -----liver disease