Scripts

Slide 1: Title

Script:

আসসালামু আলাইকুম। সম্মানিত স্যার ও ম্যাডাম, আমি **মোঃ তাহসিন ইসলাম চৌধুরী**। আজ আমি আমার থিসিস প্রোপোজাল **"Comparative Genomic Data Science for Cancer and Liver Disease Classification"** বিষয়টি উপস্থাপন করবো। এই গবেষণার মূল উদ্দেশ্য হলো ক্যান্সার ও লিভার রোগের জিন এক্সপ্রেশন ডেটা বিশ্লেষণ করে মেশিন লার্নিং-এর মাধ্যমে কার্যকর রোগ শ্রেণিবিন্যাস এবং সম্ভাব্য বায়োমার্কার শনাক্ত করা।

Slide 2: Outline

Script:

আমার উপস্থাপনায় প্রথমে গবেষণার পরিচিতি তুলে ধরবো। এরপর সমস্যা বিবৃতি, গবেষণার উদ্দেশ্য, পূর্ববর্তী গবেষণার পর্যালোচনা, প্রস্তাবিত মেথডোলজি, ব্যবহৃত টুলস ও টেকনোলজি, প্রত্যাশিত ফলাফল, উপসংহার এবং সর্বশেষে রেফারেন্স নিয়ে আলোচনা করবো।

Slide 3: Introduction

Script:

বর্তমানে Genomic Data Science আধুনিক চিকিৎসা গবেষণায় অত্যন্ত গুরুত্বপূর্ণ ভূমিকা পালন করছে। ক্যান্সার ও লিভার রোগ বিশ্বব্যাপী মৃত্যুর অন্যতম প্রধান কারণ। এই গবেষণায় পাবলিক জিন এক্সপ্রেশন ডেটাসেট ব্যবহার করে দুইটি রোগের তুলনামূলক বিশ্লেষণ করা হবে। Machine Learning-এর সাহায্যে রোগ শ্রেণিবিন্যাস উন্নত করা এবং ভবিষ্যতে Precision Medicine-এ অবদান রাখাই এই গবেষণার লক্ষ্য।

Slide 4: Problem Statement

Script:

বর্তমানে অধিকাংশ গবেষণা শুধুমাত্র একটি রোগের উপর সীমাবদ্ধ। ক্যান্সার এবং লিভার রোগের মধ্যে তুলনামূলক জিনগত বিশ্লেষণ খুবই সীমিত। এছাড়া উচ্চমাত্রার জিনোমিক ডেটা বিশ্লেষণ করা কঠিন এবং প্রচলিত পদ্ধতিতে সঠিক শ্রেণিবিন্যাস করা চ্যালেঞ্জিং। তাই একটি নির্ভরযোগ্য Machine Learning ভিত্তিক Comparative Framework প্রয়োজন।

Slide 5: Research Objectives

Script:

এই গবেষণার প্রধান উদ্দেশ্য হলো NCBI GEO থেকে ক্যান্সার এবং লিভার রোগের ডেটাসেট সংগ্রহ ও প্রিপ্রসেসিং করা। এরপর Differentially Expressed Genes শনাক্ত করা, দুই রোগের জিন এক্সপ্রেশন তুলনা করা, Gene Ontology এবং Pathway Analysis সম্পন্ন করা এবং সম্ভাব্য Biomarker আবিষ্কার করা।

Slide 6: Literature Review (Part-1)

Script:

এই অংশে প্রথম পাঁচটি গবেষণা পর্যালোচনা করা হয়েছে। Adhikari এবং Anders-এর গবেষণায় জিন এক্সপ্রেশন বিশ্লেষণের আধুনিক পদ্ধতি দেখানো হয়েছে। Byron RNA Sequencing-এর ক্লিনিক্যাল ব্যবহার ব্যাখ্যা করেছেন। Costa-Silva Computational DEG Analysis নিয়ে কাজ করেছেন এবং Fan ক্যান্সারের Single-cell Transcriptomics নিয়ে গবেষণা করেছেন। তবে এসব গবেষণায় Comparative Disease Analysis করা হয়নি।

Slide 7: Literature Review (Part-2)

Script:

এই অংশে Li, Ma এবং NCBI GEO সম্পর্কিত গবেষণাগুলো দেখানো হয়েছে। Li Cancer Diagnosis-এ Single-cell RNA Sequencing-এর গুরুত্ব তুলে ধরেছেন। Ma Multi-omics ভিত্তিক Biomarker Discovery নিয়ে কাজ করেছেন। এছাড়া NCBI GEO Database থেকে ব্যবহৃত GSE280687 এবং GSE329336 ডেটাসেট নেওয়া হয়েছে। তবে এগুলোর উপর তুলনামূলক বিশ্লেষণ এখনও সীমিত।

Slide 8: Literature Review (Part-3)

Script:

এখানে Oh, Ramachandran, Rosati, Shibata এবং Yu-এর গবেষণা উপস্থাপন করা হয়েছে। এসব গবেষণায় Liver Disease Biomarker, Genomics, DEG Pipeline এবং Batch Effect নিয়ে আলোচনা করা হয়েছে। তবে ক্যান্সার ও লিভার রোগকে একসাথে তুলনামূলকভাবে বিশ্লেষণ করার গবেষণা খুবই কম। এই গবেষণাটি সেই Research Gap পূরণ করার চেষ্টা করবে।

Slide 9: Methodology

Script:

প্রথমে NCBI GEO থেকে দুটি Gene Expression Dataset সংগ্রহ করা হবে। এরপর Duplicate Data অপসারণ, Missing Value Handling, Data Normalization এবং Feature Selection করা হবে। তারপর Dataset-কে ৭০ শতাংশ Training এবং ৩০ শতাংশ Testing-এ ভাগ করা হবে। এরপর চারটি Machine Learning Algorithm প্রশিক্ষণ ও মূল্যায়ন করা হবে।

Slide 10: Methodology Diagram

Script:

এই চিত্রটি সম্পূর্ণ গবেষণা প্রক্রিয়াটি দেখায়। প্রথমে Dataset Collection, তারপর Data Preprocessing, Feature Selection এবং Dataset Splitting করা হবে। এরপর Decision Tree, Random Forest, SVM এবং KNN Model Training করা হবে। সর্বশেষ Accuracy, Precision, Recall, F1-score এবং Confusion Matrix ব্যবহার করে সেরা মডেল নির্বাচন করা হবে।

Slide 11: Tools and Technologies

Script:

এই গবেষণায় Python Programming Language ব্যবহার করা হবে। Jupyter Notebook-এ সম্পূর্ণ কোড বাস্তবায়ন করা হবে। Dataset সংগ্রহ করা হবে NCBI GEO Database থেকে। Data Processing-এর জন্য NumPy ও Pandas, Machine Learning-এর জন্য Scikit-learn এবং ফলাফল Visualization-এর জন্য Matplotlib ও Seaborn ব্যবহার করা হবে।

Slide 12: Outcomes

Script:

এই গবেষণার মাধ্যমে একটি নির্ভরযোগ্য Machine Learning ভিত্তিক Disease Classification Framework তৈরি করা হবে। গুরুত্বপূর্ণ Gene Expression Pattern এবং সম্ভাব্য Biomarker শনাক্ত করা হবে। পাশাপাশি চারটি Machine Learning Algorithm-এর কার্যকারিতা তুলনা করা হবে, যা ভবিষ্যতে Precision Medicine এবং Biomedical Research-এ সহায়ক হবে।

Slide 13: Conclusion

Script:

পরিশেষে, এই গবেষণা ক্যান্সার এবং লিভার রোগের তুলনামূলক জিনোমিক বিশ্লেষণের জন্য একটি কার্যকর Machine Learning Framework প্রস্তাব করেছে। এর মাধ্যমে সঠিক Disease Classification, Biomarker Discovery এবং ভবিষ্যতের Precision Medicine গবেষণায় গুরুত্বপূর্ণ অবদান রাখা সম্ভব হবে।

শেষে বলবেন:

"Thank you everyone for your valuable attention. Now I am ready to answer your questions."

Questions

১. আপনার থিসিসের মূল উদ্দেশ্য কী?

উত্তর:
আমার গবেষণার মূল উদ্দেশ্য হলো Cancer এবং Liver Disease-এর Gene Expression Dataset তুলনামূলকভাবে বিশ্লেষণ করা এবং Machine Learning ব্যবহার করে সবচেয়ে ভালো Classification Model নির্ধারণ করা। পাশাপাশি সম্ভাব্য Biomarker শনাক্ত করার চেষ্টা করা।

---

২. Comparative Genomic Data Science বলতে কী বোঝায়?

উত্তর:
Comparative Genomic Data Science হলো বিভিন্ন রোগের Genomic Data তুলনা করে তাদের মিল ও পার্থক্য বিশ্লেষণ করা, যাতে Disease Mechanism এবং Biomarker সম্পর্কে ভালো ধারণা পাওয়া যায়।

---

৩. আপনি কেন Cancer এবং Liver Disease নির্বাচন করেছেন?

উত্তর:
এই দুইটি রোগ বিশ্বব্যাপী মৃত্যুর অন্যতম প্রধান কারণ। এছাড়া উভয় রোগেই Gene Expression পরিবর্তন গুরুত্বপূর্ণ ভূমিকা পালন করে। তাই তুলনামূলক বিশ্লেষণ করলে নতুন Biomarker পাওয়ার সম্ভাবনা থাকে।

---

৪. Dataset কোথা থেকে সংগ্রহ করবেন?

উত্তর:
Dataset NCBI-এর Gene Expression Omnibus (GEO) Database থেকে সংগ্রহ করা হবে।

Cancer Dataset: **GSE329336**

Liver Disease Dataset: **GSE280687**

---

৫. NCBI GEO কী?

উত্তর:
NCBI GEO হলো একটি Public Genomic Database যেখানে Gene Expression এবং Functional Genomics-এর Dataset সংরক্ষিত থাকে এবং গবেষকরা বিনামূল্যে ব্যবহার করতে পারেন।

---

৬. Gene Expression কী?

উত্তর:
Gene Expression হলো কোনো Gene কতটা সক্রিয় এবং কত পরিমাণ RNA বা Protein তৈরি করছে তার পরিমাপ।

---

৭. Biomarker কী?

উত্তর:
Biomarker হলো এমন একটি Biological Indicator যা কোনো রোগ নির্ণয়, পর্যবেক্ষণ অথবা চিকিৎসার কার্যকারিতা নির্ধারণে ব্যবহৃত হয়।

---

৮. Data Preprocessing কেন প্রয়োজন?

উত্তর:
Raw Data-তে Duplicate Data, Missing Value এবং Noise থাকতে পারে। এগুলো সরিয়ে Data Quality উন্নত করার জন্য Data Preprocessing করা হয়।

---

৯. Data Normalization কী?

উত্তর:
Normalization হলো সব Feature-কে একই Scale-এ নিয়ে আসার প্রক্রিয়া, যাতে বড় মানের Feature অন্য Feature-এর উপর প্রভাব না ফেলে।

---

১০. Feature Selection কেন করবেন?

উত্তর:
Gene Dataset-এ হাজার হাজার Gene থাকে। সবগুলো গুরুত্বপূর্ণ নয়। তাই গুরুত্বপূর্ণ Gene নির্বাচন করলে Model দ্রুত কাজ করে এবং Accuracy বৃদ্ধি পায়।

---

১১. Dataset কেন 70:30 ভাগ করবেন?

উত্তর:
৭০% Data Model Training-এর জন্য এবং ৩০% Data Testing-এর জন্য ব্যবহার করা হবে যাতে Model-এর Performance নিরপেক্ষভাবে মূল্যায়ন করা যায়।

---

১২. কেন চারটি Machine Learning Algorithm ব্যবহার করবেন?

উত্তর:
বিভিন্ন Algorithm-এর Performance তুলনা করার জন্য Decision Tree, Random Forest, SVM এবং KNN ব্যবহার করা হবে।

---

১৩. Decision Tree কী?

উত্তর:
Decision Tree একটি Tree-based Classification Algorithm যা বিভিন্ন Decision Rule অনুসরণ করে Data Classification করে।

---

১৪. Random Forest কী?

উত্তর:
Random Forest হলো একাধিক Decision Tree-এর সমন্বয়ে তৈরি একটি Ensemble Learning Algorithm যা Accuracy বৃদ্ধি করে এবং Overfitting কমায়।

---

১৫. SVM কী?

উত্তর:
Support Vector Machine এমন একটি Algorithm যা বিভিন্ন Class-এর মধ্যে সর্বোচ্চ দূরত্ব রেখে একটি Optimal Decision Boundary তৈরি করে।

---

১৬. KNN কী?

উত্তর:
K-Nearest Neighbors নতুন Data-এর কাছাকাছি থাকা প্রতিবেশী Data-এর Label দেখে Classification করে।

---

১৭. কোন Algorithm সবচেয়ে ভালো হতে পারে?

উত্তর:
Genomic Dataset সাধারণত High-dimensional হওয়ায় SVM এবং Random Forest ভালো Performance দিতে পারে। তবে চূড়ান্ত ফলাফল Experiment-এর উপর নির্ভর করবে।

---

১৮. Accuracy কী?

উত্তর:
Accuracy হলো মোট Prediction-এর মধ্যে কতগুলো সঠিক Prediction হয়েছে তার শতকরা হার।

---

১৯. Precision কী?

উত্তর:
Model Positive বলেছে এমন Prediction-এর মধ্যে কতগুলো সত্যিই Positive ছিল সেটাই Precision।

---

২০. Recall কী?

উত্তর:
Actual Positive Data-এর মধ্যে Model কতগুলো সঠিকভাবে শনাক্ত করেছে সেটাই Recall।

---

২১. F1-score কী?

উত্তর:
Precision এবং Recall-এর Balanced Measure-কে F1-score বলা হয়।

---

২২. Confusion Matrix কী?

উত্তর:
Confusion Matrix হলো একটি Table যেখানে True Positive, False Positive, True Negative এবং False Negative দেখানো হয়।

---

২৩. আপনার গবেষণার নতুনত্ব (Novelty) কী?

উত্তর:
আমাদের গবেষণায় Cancer এবং Liver Disease-এর Comparative Genomic Analysis করা হবে এবং একই Framework-এ চারটি Machine Learning Algorithm-এর Performance তুলনা করা হবে। এটি পূর্ববর্তী অনেক গবেষণায় করা হয়নি।

---

২৪. Research Gap কী?

উত্তর:
বেশিরভাগ গবেষণা শুধুমাত্র একটি রোগ নিয়ে কাজ করেছে। Cancer এবং Liver Disease-এর Comparative Genomic Analysis এবং Machine Learning Performance Comparison খুবই সীমিত।

---

২৫. আপনার Expected Outcome কী?

উত্তর:
সবচেয়ে কার্যকর Classification Model নির্ধারণ, গুরুত্বপূর্ণ Gene Pattern শনাক্ত করা এবং ভবিষ্যতের Biomarker Discovery ও Precision Medicine গবেষণায় সহায়তা করা।

---

২৬. যদি Accuracy কম আসে তাহলে কী করবেন?

উত্তর:
Feature Selection উন্নত করব, Hyperparameter Tuning করব, Cross Validation ব্যবহার করব এবং প্রয়োজনে Deep Learning Model পরীক্ষা করব।

---

২৭. Machine Learning-এর পরিবর্তে Deep Learning কেন ব্যবহার করেননি?

উত্তর:
বর্তমান গবেষণায় Dataset তুলনামূলকভাবে সীমিত। তাই প্রথমে Machine Learning Model ব্যবহার করছি। ভবিষ্যতে CNN, ANN বা GNN-এর মতো Deep Learning Model নিয়ে কাজ করার পরিকল্পনা রয়েছে।

---

২৮. ভবিষ্যতে এই গবেষণা কীভাবে উন্নত করা যাবে?

উত্তর:
আরও বড় Dataset, Multi-omics Data এবং Deep Learning ব্যবহার করে আরও নির্ভুল Disease Classification এবং Biomarker Discovery করা সম্ভব।